

**НАБОРИ ДАНИХ. ШКАЛИ.
ВИЗНАЧЕННЯ МІР
БЛИЗЬКОСТІ МІЖ
ОБ'ЄКТАМИ
НАБОРУ ДАНИХ**

Вимірювання

У процесі підготовки даних вимірюються характеристики об'єкту. **Вимірювання** — процес присвоєння чисел характеристикам досліджуваних об'єктів згідно з визначеним правилом — **шкалою**.

Зазвичай виділяють п'ять типів шкал: **номінальна, порядкова, інтервальна, відносна і дихотомічна**.

Номінальна шкала (англ. Nominal Scale) містить тільки категорії; дані в ній не можуть бути впорядковані, над ними неможливо проводити арифметичні дії. Номінальна шкала складається з назв, категорій, імен для класифікації і сортування об'єктів або спостережень за певною ознакою. Для цієї шкали можна застосовувати лише прості операції порівняння: дорівнює (=) та не дорівнює ($\neq$). Прикладами номінальної шкали є: назви факультетів, прізвища тощо.

Порядкова шкала (англ. Ordinal Scale) характеризується тим, що в ній числа привласнюють об'єктам для позначення відносної позиції об'єктів, але не величини відмінностей між ними, тобто вимірювання в порядковій шкалі містять інформацію тільки про порядок величин, але не відповідає на питання типу "наскільки одна величина більша за іншу". Для цієї шкали можна застосовувати лише такі операції, як: дорівнює (=), не дорівнює ($\neq$), більше ($>$) та менше ($<$). Приклади порядкової шкали: освіта (початкова, середня, вища), вчене звання (доцент, старший дослідник, професор) тощо.

В **інтервальній шкалі** (англ. Interval Scale) різниці між значеннями можуть бути обчислені, проте їхні відношення не мають сенсу. Ця шкала дозволяє знаходити різницю між двома величинами, має властивості номінальної і порядкової шкал, а також дозволяє визначити кількісну зміну ознаки. Інтервальна шкала, на відміну від дискретних номінальної і порядкової, є неперервною. Вона дозволяє здійснювати точні вимірювання ознаки і виконувати арифметичні операції додавання, віднімання, множення, ділення. Для цієї шкали можна застосовувати лише такі операції, як дорівнює (=), не дорівнює ($\neq$), більше ($>$), менше ($<$), операції додавання (+) і віднімання (-). Прикладом такої шкали є температура повітря: можна говорити, що -10°C на 20 градусів менше, ніж $+10^{\circ}\text{C}$, проте порівняння у скільки разів менше не має сенсу.

Відносна шкала (англ. Ratio Scale) характеризується існуванням певної точки відліку, що наповнює сенсом відношення між значеннями. Для цієї шкали можна застосовувати такі операції, як дорівнює (=), не дорівнює ($\neq$), більше ($>$), менше ($<$), операції додавання (+) і віднімання (-), множення (*) та ділення (/). Прикладом такої шкали є заробітна плата.

Дихотомічна шкала (англ. Dichotomous Scale) містить тільки дві категорії. Приклад такої шкали: стать (чоловіча і жіноча). Це частковий випадок категоріальної шкали.

Приклад використання різних шкал для вимірювання властивостей різних об'єктів наведено в таблиці.

<i>Номер об'єкта</i>	<i>Професія (номінальна шкала)</i>	<i>Середній бал (інтервальна шкала)</i>	<i>Освіта (порядкова шкала)</i>
1	Слюсар	22	Середня
2	Вчений	55	Вища
3	Вчитель	47	Вища

Типи шкал

Тип шкали		Допустимі операції (математичні, логічні)				Приклади	Особливості
		= ≠	> <	+ -	* /		
Категоріальні	Номінальна	✓	–	–	–	Стать, національність, клінічний діагноз	Дані не можуть упорядковуватися
	Порядкова	✓	✓	–	–	Оцінка, посада, військовий ранг	Порівняння не числове: визначають порядок слідування
Числові (метричні)	Інтервальна	✓	✓	✓	–	Календарний час, температура за Цельсієм	Нуль не означає відсутність ознаки
	Відношень	✓	✓	✓	✓	Вага, ціна, ріст, температура за Кельвіном	Нуль означає відсутність ознаки

Сутність класифікації та кластеризації даних

Кластерний аналіз та класифікацію даних відносять до найбільш поширених задач Data Mining.

Класифікація (англ. *Classification*) – це задача розбиття множини об'єктів (спостережень, подій) на апіорно задані групи – **класи**, відповідно до значень змінних, які характеризують властивості цих об'єктів.

За допомогою класифікації встановлюється функціональна залежність між вхідними і дискретними вихідними змінними та здійснюється віднесення нових об'єктів до одного зі заздалегідь відомих класів. Використовують також термін *розпізнавання образів* (англ. *pattern recognition*), який можна вважати синонімом.

Кластеризація (англ. *Clustering*) – це задача групування множини об'єктів (спостережень, подій) на групи – **кластери**, на основі даних, що описують сутність цих об'єктів – значень змінних, які характеризують їх властивості.

Кожен кластер або клас містить схожі об'єкти, які мають приблизно однакові властивості та суттєво відрізняються від об'єктів інших кластерів чи, відповідно, класів.

Задача кластеризації є логічним продовженням ідеї класифікації й застосовується часто на початкових етапах дослідження для виявлення внутрішньої структури даних, після чого застосовують інші методи та алгоритми Data Mining.

Для розв'язання задач класифікації та кластеризації існує багато методів, в основі яких лежать поняття мір близькості, відстані між об'єктами.

Матриця даних, поняття подібності та несхожості об'єктів

Сукупність об'єктів набору даних та змінних, які містять значення їх характеристик, зручно представити у вигляді таблиці, кожен рядок якої відповідає одному об'єкту, а кожен стовпець – певній змінній, яка міняється від об'єкта до об'єкта.

Об'єкти	Характеристики			
	ПІБ клієнта	Вік	Сімейний стан	Дохід
	Шевченко А. Д.	24	Розлучений	12500
	Новицька Л. І.	22	Одружена	10520
	Іванов М. С.	35	Одружений	7580
	Савицька Л. М.	45	Одружена	6900

Така таблиця містить дані для формування **матриці даних** (англ. *Data matrix*), в якій рядкам відповідають об'єкти, а стовпцям – змінні, що характеризують ці об'єкти:

$$\begin{pmatrix} x_{11} & \dots & x_{1m} \\ \dots & \dots & \dots \\ x_{n1} & \dots & x_{nm} \end{pmatrix}$$

Для оцінки близькості об'єктів один до одного розраховують міри близькості між ними. **Міри близькості** (англ. *Proximity measures*) є математичними методами обчислення подібності чи несхожості об'єктів набору даних шляхом визначення **мір подібності** (англ. *Similarity measures*) або **мір несхожості** (англ. *Dissimilarity measures*).

Поняття подібності є протилежним до поняття несхожості у багатомірному просторі ознак, оскільки меншій мірі несхожості між об'єктами відповідає більше значення міри подібності.

Якщо об'єкти не схожі, міра подібності повертає значення, близькі до нуля або 0, а міра несхожості повертає значення, близькі до одиниці або 1. Для схожих об'єктів навпаки, міра подібності повертає значення, близькі до одиниці або 1 (якщо об'єкти однакові), а міра несхожості повертає значення, близькі до нуля або 0 (якщо об'єкти однакові).

Матриці близькості, таблиці спряженості

Для набору даних, атрибути яких представлені у числових (метричних) шкалах, використовують матрицю відстаней (англ. Distance matrix), стовпці та рядки якої відповідають об'єктам вхідної множини даних. Елементами матриці відстаней D є значення відстані d_{ij} між об'єктами, які розташовані у рядку i та стовпці j . Матриця відстаней є симетричною відносно головної діагоналі, яка містить нулі:

$$D = \begin{pmatrix} 0 & d_{12} & \dots & d_{1n} \\ d_{21} & 0 & \dots & d_{2n} \\ \dots & \dots & \dots & \dots \\ d_{n1} & d_{n2} & \dots & 0 \end{pmatrix}$$

Матриця відстані є **матрицею несхожості** (англ. Dissimilarity matrix) розмірністю $n \times n$ (де n – кількість об'єктів набору даних), оскільки її елементи – відстані між об'єктами, є їх мірами несхожості.

Є ряд задач аналізу даних, у яких при проведенні класифікації чи кластеризації будують **матрицю подібності** (англ. Similarity matrix), яка також є симетричною відносно головної діагоналі і має розмірність $n \times n$, а її головна діагональ містить одиниці

$$S = \begin{pmatrix} 1 & s_{12} & \dots & s_{1n} \\ s_{21} & 1 & \dots & s_{2n} \\ \dots & \dots & \dots & \dots \\ s_{n1} & s_{n2} & \dots & 1 \end{pmatrix}$$

Спосіб визначення мір близькості між об'єктами залежить від типу атрибутів набору даних та шкал, у яких їх вимірюють. У разі визначення за певним методом міри несхожості $d_{ij} = d(x_i, x_j)$ між двома об'єктами x_i і x_j , міра подібності цих об'єктів $s_{ij} = s(x_i, x_j)$ може бути розрахована таким чином: $s_{ij} = 1 - d_{ij}$. Наведена формула справедлива для мір несхожості, які знаходяться у діапазоні $[0, 1]$.

Матриця несхожості та матриця подібності є різними видами *матриці близькості*

Якщо у алгоритмі використовують відстань між об'єктами або інші міри несхожості, то в основі віднесення об'єктів до одного класу чи кластеру лежить знаходження мінімуму відстаней (мір несхожості) між ними. У разі використання в алгоритмі мір подібності, основою об'єднання об'єктів в одному класі чи кластері є знаходження максимуму мір подібності між ними.

МІРИ БЛИЗЬКОСТІ ДЛЯ РІЗНИХ ТИПІВ ДАНИХ

Міри близькості для простих атрибутів

Тип шкали (атрибуту)	Міра несхожості	Міра подібності
Номінальна шкала	$d(x_i, x_j) = \begin{cases} 0, & x_i = x_j \\ 1, & x_i \neq x_j \end{cases}$	$s(x_i, x_j) = \begin{cases} 1, & x_i = x_j \\ 0, & x_i \neq x_j \end{cases}$
Порядкова шкала	$d(x_i, x_j) = \frac{ x_i - x_j }{n - 1}$ (значення атрибуту представлені цілими числами з проміжку $\{0, \dots, n - 1\}$, де n – кількість значень атрибуту)	$s(x_i, x_j) = 1 - d(x_i, x_j)$
Числова (інтервальна та шкала відно- шень)	$d(x_i, x_j) = x_i - x_j $	$s(x_i, x_j) = \frac{1}{1 + d(x_i, x_j)},$ $s(x_i, x_j) = 1 - \frac{d(x_i, x_j) - d_{\min}}{d_{\max} - d_{\min}}$

Визначення мір близькості для числових даних

Для числових даних мірою близькості між об'єктами – мірою їх несхожості – є відстань, яка розраховується за формулами, що містять числові атрибути – характеристики цих об'єктів.

Міри відстаней між об'єктами для метричних шкал

Метрика	Формула
Відстань Евкліда	$d_E(x_i, x_j) = \sqrt{\sum_{t=1}^m (x_{it} - x_{jt})^2}$
Квадрат відстані Евкліда	$d_E^2(x_i, x_j) = \sum_{t=1}^m (x_{it} - x_{jt})^2$
Манхеттенська відстань (відстань міських кварталів)	$d_H(x_i, x_j) = \sum_{t=1}^m x_{it} - x_{jt} $
Відстань Чебишева	$d_\infty(x_i, x_j) = \max_{1 \leq t \leq m} x_{it} - x_{jt} $
Відстань Мінковського	$d_{Minc}(x_i, x_j) = \sqrt[p]{\sum_{t=1}^m x_{it} - x_{jt} ^p}$
Степенева відстань	$d_{cm}(x_i, x_j) = \sqrt[r]{\sum_{t=1}^m x_{it} - x_{jt} ^p}$
Відстань Махаланобіса	$d_M(x_i, x_j) = \sqrt{(X_i - X_j)^T S^{-1} (X_i - X_j)}$ $S = (s_{kl}); k \in \{1, \dots, m\}, l \in \{1, \dots, m\}$ $s_{kl} = \frac{1}{n} \sum_{t=1}^n (x_{tk} - \bar{x}_k)(x_{tl} - \bar{x}_l)$
Пікова відстань	$d_L(x_i, x_j) = \frac{1}{m} \sum_{t=1}^m \frac{ x_{it} - x_{jt} }{x_{it} + x_{jt}}$
Відстань Джеффріса-Матусіти	$d_{DM}(x_i, x_j) = \sqrt{\sum_{t=1}^m (\sqrt{x_{it}} - \sqrt{x_{jt}})^2}$

Приклад 1. Для 3-х об'єктів (осіб) визначити міри близькості за номінальною ознакою «стать», яка може приймати два значення: «чоловіча», «жіноча» (табл.) та побудувати матриці близькості (несхожості і подібності) для заданого набору даних.

Значення однієї номінальної ознаки для 3-х об'єктів

Об'єкти	Ознака x_i – «стать»
1	чоловіча
2	жіноча
3	чоловіча

Знаходимо міри несхожості між об'єктами: $d_{1,1} = 0$ (значення змінної для одного й того ж об'єкта співпадає: $x_1 = x_1 = \text{"чоловіча"}$, тому несхожість є мінімальною), $d_{1,2} = d_{2,1} = 1$ (значення змінної для двох об'єктів різне: $x_1 \neq x_2$, оскільки $x_1 = \text{"чоловіча"}$, а $x_2 = \text{"жіноча"}$, тому несхожість є максимальною). Аналогічно знаходимо: $d_{1,3} = d_{3,1} = 0, d_{2,2} = 0, d_{2,3} = d_{3,2} = 1, d_{3,3} = 0$, та будуємо матрицю несхожості між об'єктами за однією номінальною ознакою:

$$D = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}.$$

Враховуючи, що $s(x_i, x_j) = 1 - d(x_i, x_j)$, розраховуємо міри подібності між об'єктами: $s_{1,1} = 1, s_{1,2} = s_{2,1} = 0, s_{1,3} = s_{3,1} = 1, s_{2,2} = 1, s_{2,3} = s_{3,2} = 0, s_{3,3} = 1$. Отримуємо матрицю подібності за однією номінальною ознакою:

$$S = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}.$$

Приклад 2. Для 4-х об'єктів (студентів) визначити міри близькості за порядковою ознакою „оцінка”, яка приймає три значення: «задовільно», «добре», «відмінно» (табл.) та побудувати матриці близькості (несхожості і подібності) для заданого набору даних.

Значення однієї порядкової ознаки для 4-х об'єктів

Об'єкти	Ознака x_i – «оцінка»
1	добре
2	задовільно
3	добре
4	відмінно

Відповідь:

$$D = \begin{pmatrix} 0 & 0,5 & 0 & 0,5 \\ 0,5 & 0 & 0,5 & 1 \\ 0 & 0,5 & 0 & 0,5 \\ 0,5 & 1 & 0,5 & 0 \end{pmatrix}.$$

$$S = \begin{pmatrix} 1 & 0,5 & 1 & 0,5 \\ 0,5 & 1 & 0,5 & 0 \\ 1 & 0,5 & 1 & 0,5 \\ 0,5 & 0 & 0,5 & 1 \end{pmatrix}.$$

Приклад 3. Для 3-х об'єктів визначити міри близькості за числовою ознакою «вага», яка приймає два значення: 65 кг і 55 кг (табл) та побудувати матриці близькості (несхожості і подібності) для заданого набору даних.

Значення однієї числової ознаки для 3-х об'єктів

Об'єкти	Ознака x_i – „вага”
1	65
2	55
3	65

Відповідь:

$$D = \begin{pmatrix} 0 & 10 & 0 \\ 10 & 0 & 10 \\ 0 & 10 & 0 \end{pmatrix}.$$

$$S = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}.$$