

ІЄРАРХІЧНИЙ КЛАСТЕРНИЙ АНАЛІЗ ДАНИХ


Типи алгоритмів ієрархічної кластеризації

У процесі здійснення *ієрархічного кластерного аналізу* будують систему вкладених розбиттів набору даних на кластери й отримують на виході *дерево кластерів*, коренем якого є весь набір даних, а листи є найбільш дрібними кластерами – об'єктами набору даних.

Серед алгоритмів ієрархічної кластеризації виділяють два основних типи.

- *Агломеративні алгоритми* (висхідні, побудова кластерів здійснюється знизу вгору) – більш поширені, на першому кроці кожен об'єкт вважається окремим кластером, а потім здійснюється об'єднання кластерів у все більші, поки всі об'єкти набору даних не будуть утворювати один кластер.
- *Дивізімні алгоритми* (спадні, побудова кластерів здійснюється зверху вниз) – на першому кроці всі об'єкти набору даних відносять до одного кластера, який потім розбивається на все більш дрібні кластери.

- Послідовність об'єднання чи розбиття кластерів графічно може бути представлена у вигляді *дендрограми*, яка у вигляді дерева відображає кластери, утворені на кожному етапі ітерації. При створенні дендрограми використовують побудовану матрицю близькості, яка містить розраховані за обраним методом попарні міри близькості між об'єктами заданого набору даних.



Етапи ієрархічного кластерного аналізу

1. Вибір змінних для кластеризації, які відповідають характеристикам об'єктів набору даних, суттєвим для предметної області, в якій здійснюється аналіз.
2. Вибір методу розрахунку мір близькості між об'єктами – подібності чи несхожості (відстані).
3. Побудова матриці близькості – несхожості (відстані для метричних даних) чи подібності на основі попарно розрахованих за обраним методом мір близькості між об'єктами набору даних.
4. Вибір методу зв'язку кластерів у процесі їх об'єднання (для агломеративного алгоритму) чи поділу (для дивізімного алгоритму) та формування кластерів, який є ітеративним:
 - Для *агломеративного алгоритму*:
 - на першому кроці об'єднують у один кластер пару найближчих кластерів (об'єктів), порівнюючи попарні міри близькості між усіма об'єктами, які містяться у матриці близькості;
 - на наступних кроках здійснюється об'єднання найближчих кластерів за обраним методом їх зв'язку та оновлення матриці близькості доти, поки усі кластери не будуть об'єднані в один.
 - Для *дивізімного алгоритму*:
 - на першому кроці знаходять пару найдальших об'єктів, порівнюючи попарні міри близькості між усіма об'єктами, які містяться у матриці близькості;
 - здійснюють поділ об'єктів, що залишилися, на два кластери на основі їх близькості до одного з двох виділених на попередньому етапі об'єктів;
 - два попередні кроки повторюють доти, поки усі об'єкти не будуть поділені на кластери таким чином, що кожен об'єкт буде окремим кластером.

5. Визначення оптимальної кількості кластерів, яка буде відображати внутрішню структуру набору даних. **Оптимальну кількість кластерів** розраховують як різницю між кількістю об'єктів набору даних та номером етапу ітерації, на якому відстань між кластерами, які об'єднуються (діляться), змінюється стрибкоподібно.
6. Інтерпретація результатів – виявлення внутрішньої структури набору даних, що передбачає аналіз вмісту кластерів та визначення спільних характеристик об'єктів кожного кластеру. Цей етап є досить складним і залежить від мети дослідника.

Методи зв'язку кластерів

На етапах ітерації ієрархічного кластерного аналізу застосовують різні *методи зв'язку*, які є критеріями під час об'єднання (для агломеративного алгоритму) чи поділу (для дивізімного алгоритму) кластерів.

До *основних методів зв'язку*, що лежать в основі визначення близькості двох кластерів, відносять наступні.

1. Найближчого (ближнього) сусіда або *одиначного зв'язку*: за відстань між кластерами приймають відстань між найближчими об'єктами цих кластерів. Результуючі кластери мають тенденцію об'єднуватися у ланцюжки.

2. Найбільш віддаленого (дальнього) сусіда або *повного зв'язку*: за відстань між кластерами приймають відстань між найбільш віддаленими об'єктами цих кластерів. Цей метод доцільно застосовувати у випадках, коли кластери мають вигляд сильно віддалених одна від одної скупчень.

3. Середнього або міжгрупового зв'язку:

а) *незваженого*: відстань між двома різними кластерами обчислюється як середня відстань між усіма парами об'єктів у них. Метод ефективний, коли об'єкти формують різні групи, однак він працює добре й у випадках протяжних (ланцюжкового типу) кластерів;

б) *зваженого*: відрізняється від попереднього врахуванням вагових коефіцієнтів – розмірів кластерів (кількості об'єктів у них). Цей метод доцільно застосовувати, коли передбачаються нерівні розміри кластерів.

4. **Центроїдний метод** (англ. *Centroid Linkage*):

а) *незважений*: відстань між двома кластерами визначається як відстань між їхніми *центрами ваги* – *центроїдами*, які розраховують як точки у просторі ознак набору даних із координатами, рівними середнім значенням змінних усіх об'єктів кластера. У цьому методі більший вклад у розрахунок відстані будуть вносити великі кластери.

б) *зважений*: відрізняється від попереднього врахуванням вагових коефіцієнтів – розмірів кластерів (кількості об'єктів у них), що робить однаковим вклад у розрахунок відстаней кластерів різних розмірів.

5. **Медіанний метод**: відстань між будь-яким кластером та новим кластером, отриманим у результаті об'єднання двох кластерів, визначається як відстань між цим кластером та серединою відрізка, що з'єднує об'єднані кластери.

6. **Метод Уорда**: заснований на мінімізації загальної внутрішньогрупової суми квадратів у результаті об'єднання кластерів, яка визначається як сума квадратів відстаней між усіма об'єктами у кластері й центроїдом кластера. Метод направлений на об'єднання близько розташованих кластерів і має тенденцію до створення кластерів малого розміру.

Приклад 1. Для 6-ти об'єктів, кожен із яких характеризується двома числовими ознаками: x – обсяг продукції, що випускається, та y – середньорічна вартість основних промислово-виробничих фондів (табл. 1), побудувати матрицю відстаней за метрикою – відстань Евкліда.

Ознаки	Об'єкти					
	1	2	3	4	5	6
x	2	4	5	12	14	15
y	8	10	7	6	6	4

Приклад 2. Використовуючи побудовану у прикладі 1 матрицю відстаней, здійснити ієрархічну агломеративну кластеризацію з використанням методу найближчого сусіда.

Приклад 3. Використовуючи побудовану у *прикладі 1* матрицю відстаней, здійснити ієрархічну агломеративну кластеризацію з використанням методу найдалшого сусіда.