

Ієрархічна кластеризація: метод найближчого сусіда

Приклад 2. Використовуючи побудовану у прикладі 1 матрицю відстаней, здійснити ієрархічну агломеративну кластеризацію з використанням методу найближчого сусіда.

1. При формуванні нової матриці відстаней стовпці 4 і 5 будуть об'єднані у одну групу і рядки 4 і 5 будуть об'єднані у одну групу. У разі використання методу найближчого сусіда при їх об'єднанні з двох значень залишають те, яке є меншим (рис. 5.4). Значення на перетині інших стовпців матриці відстаней залишаємо без змін.




Рис. 5.4. Перший етап об'єднання кластерів за методом найближчого сусіда

2. У новій матриці відстаней найменше значення рівне 2,24 є відстанню між кластером (4, 5) та об'єктом 6 (рис. 5.4, б), тому їх можна об'єднати у один кластер, залишаючи менші значення при об'єднанні відповідних комірок (рис. 5.5, а). Значення на перетині інших стовпців матриці відстаней залишаємо без змін. Після об'єднання отримуємо наступну матрицю відстаней меншого розміру (рис. 5.5, б).

3. У новій матриці відстаней найменше значення рівне 2,83 і є відстанню між об'єктами 1 та 2 (рис. 5.5, б), тому їх можна об'єднати у один кластер, залишаючи менше значення у комірках при об'єднанні (рис. 5.6, а). Після об'єднання отримуємо наступну матрицю відстаней (рис. 5.6, б).




Рис. 5.5. Другий етап об'єднання кластерів за методом найближчого сусіда




Рис. 5.6. Третій етап об'єднання кластерів за методом найближчого сусіда

4. У новій матриці відстаней найменше значення рівне 3,16 і є відстанню між кластером (1, 2) та об'єктом 3 (рис. 5.6, б), тому їх можна об'єднати у один кластер (рис. 5.7, а). Після об'єднання маємо два кластери (1, 2, 3) та (4, 5, 6), відстань між якими дорівнює 0,7 (рис. 5.7, б).




Рис. 5.7. Останній етап об'єднання кластерів за методом найближчого сусіда

5. На останньому етапі кластеризації кластери (1, 2, 3) та (4, 5, 6) об'єднують у один кластер (1, 2, 3, 4, 5, 6), який буде містити усі об'єкти набору даних.

6. Результати проведеної кластеризації можна представити графічно у вигляді дендрограми (рис. 5.8).




Рис. 5.8. Дендрограма для проведеної ієрархічної кластеризації

7. Аналіз дендрограми показує, що на останньому етапі спостерігається різкий скачок відстані між кластерами, які об'єднуються, порівняно з відстанями об'єднаних кластерів попередніх етапів (7,07 порівняно з 3, 2,24, 2,83, 3,16). Це дає можливість розрахувати оптимальне число кластерів, рівне різниці кількості об'єктів – 6 та номеру етапу, після якого відстань збільшується стрибкоподібно – 4. Тобто оптимальне число кластерів дорівнює $6 - 4 = 2$, а склад кластерів визначаємо з даних, отриманих у п. 4 (рис. 5.7): кластер 1 містить об'єкти (1, 2, 3), а кластер 2 містить об'єкти (4, 5, 6).